

한문 고전 번역 모델 개발을 통한 한문학 자연어 처리 가능성 연구

윤주환

성균관대학교

e-mail : yunjh1126@g.skku.edu

Exploring the Feasibility of Natural Language Processing for Classical Chinese Literature through the Development of a Translation Model

Juhwan Yun

Sungkyunkwan University

요약

본 연구는 한문 고전 텍스트의 현대 한국어 번역을 위한 Seq2Seq 기반의 자연어 처리 모델을 개발하고, 이를 통해 한문학 자연어 처리의 가능성을 탐구하였다. 한문은 동아시아 전통 문서에서 중요한 역할을 해왔지만, 그 문법적 복잡성과 현대 언어와의 차이로 인해 자연어 처리에서 많은 어려움을 겪고 있다. 연구의 주된 목표는 한문을 현대 한국어로 효과적으로 번역할 수 있는 모델을 설계하고, 한문학 연구와 번역에서의 도전 과제를 분석하는 것이다.

본 연구에서는 Seq2Seq 모델과 어텐션 메커니즘을 활용하여 한문 고전 번역 모델을 개발하였다. 모델 학습을 위해 조선왕조실록과 승정원일기 데이터를 수집하고 전처리하였으며, 모델의 성능을 평가한 결과, 번역 정확도가 제한적임을 확인하였다. 분석된 문제로는 데이터베이스의 비표준화, 토큰화의 어려움, 유니코드 사용으로 인한 메모리 문제, 의역된 번역문으로 인한 토큰 길이 차이, 한자의 의미적 복잡성 등이 있다.

결론적으로, 본 연구는 한문학 자연어 처리의 주요 도전 과제를 규명하였으며, 데이터 품질 향상, 토큰화 기술 개발, 모델 성능 개선 등을 위한 향후 연구 방향을 제시하였다. 연구 결과는 한문학 연구의 자동화 및 효율성 증진에 기여할 것으로 기대되며, 자연어 처리 기술의 발전에 중요한 기초 자료로 활용될 수 있다.

주요어: 한문, 자연어 처리, Seq2Seq 모델, 어텐션 메커니즘, 데이터 전처리, 번역 모델

1. 서론

한문(漢文)은 동아시아의 전통 문서에서 중요한 역할을 해온 언어로, 오늘날에도 역사, 철학, 문학 등의 학문적 연구에서 중요한 자료로 활용되고 있다. 그러나 한문은 문법적으로 현대 언어와 상이한 점이 많고, 어순 및 문체가 복잡하여 현대 독자가 이를 이해하는 데 어려움이 있다. 이러한 어려움을 해결하기 위해, 최근 한문 텍스트를 현대어로 번역하는 자동화 도구나 한문 고전의 내용을 분석하는 자연어 처리(Natural Language Processing, NLP) 기술에 대한 연구가 활발히 진행되고 있다.

자연어 처리는 컴퓨터가 인간의 언어를 이해하고 처리할

수 있도록 하는 기술로, 텍스트 분석, 기계 번역, 감정 분석 등 다양한 응용 분야에서 활용되고 있다. 특히 딥러닝 기술의 발전으로 인해 자연어 처리의 성능이 크게 향상되면서, 다양한 언어에 대해 효과적인 모델들이 개발되고 있다. 그러나, 한문과 같은 고전 언어에 대한 자연어 처리 연구는 상대적으로 부족한 실정이다.

본 연구는 한문 고전 번역 모델 개발 과정을 통해 한문학 자연어 처리의 가능성을 탐구하는 데 목적을 두고 있다. 이를 위해 한문 고전 번역의 어려움과 한계를 분석하고, 최신 자연어 처리 기법을 적용하여 한문 고전 텍스트를 현대 한국어로 번역하는 모델을 개발하고자 한다. 또한, 이러

한 번역 모델이 한문학 연구에 미칠 수 있는 영향을 평가하고, 이를 바탕으로 한문 자연어 처리 기술의 발전 방향을 제시하고자 한다.

2. 이론적 배경

2-1. Seq2Seq 모델의 개요

Seq2Seq(Sequence-to-Sequence) 모델은 자연어 처리 분야에서 널리 활용되는 딥러닝 기법 중 하나로, 특히 기계 번역에서 큰 성과를 거두어 왔다. 이 모델은 입력된 시퀀스를 인코더(Encoder)라는 신경망이 고정된 크기의 벡터로 변환한 후, 디코더(Decoder)라는 신경망이 이를 다시 출력 시퀀스로 변환하는 방식으로 작동한다. Seq2Seq 모델의 가장 큰 특징은 인코더와 디코더가 함께 학습되며, 이 과정에서 시퀀스 간의 복잡한 관계를 효과적으로 학습할 수 있다는 점이다. 초기에는 RNN(순환신경망) 기반으로 개발되었으나, LSTM(Long Short-Term Memory) 및 GRU(Gated Recurrent Unit)와 같은 고급 신경망 구조를 도입함으로써 장기 의존성을 효과적으로 처리할 수 있게 되었다.

2-2. Seq2Seq 모델의 개발 및 적용 사례

기존의 Seq2Seq 모델은 주로 영어-프랑스어와 같은 언어 쌍 간의 기계 번역에 사용되었으며, Sutskever et al. (2014)와 같은 연구는 이 모델이 복잡한 문장 구조를 처리하는 데 있어 기존의 통계적 기계 번역(SMT) 기법보다 우수한 성능을 보인다는 것을 입증했다. 이후 Bahdanau et al. (2015)는 주의(attention) 메커니즘을 도입하여 디코더가 인코딩된 전체 시퀀스를 참조하면서도 특정 단어에 집중할 수 있게 함으로써, 번역의 정확도와 자연스러움을 크게 향상시켰다. 이러한 발전은 특히 문맥적 정보가 중요한 번역 작업에서 큰 의미를 갖는다.

2-3. 한문 번역의 특수성과 도전 과제

한문(漢文)은 그 자체로 매우 간결하면서도 복잡한 문법적 구조를 가지고 있으며, 현대 한국어나 다른 현대 언어들과 비교했을 때 문장의 어순, 생략된 주어 및 목적어, 다양한 함축적 의미 등으로 인해 기계 번역이 특히 어렵다. 또한 한문은 표의문자인 한자를 사용하므로, 같은 한자가 문맥에 따라 여러 가지 의미로 해석될 수 있다. 이러한 특성은 Seq2Seq 모델을 한문 번역에 적용하는 데 있어 추가적인 도전 과제로 작용한다.

2-4. 조선왕조실록과 승정원일기 데이터의 활용

조선왕조실록과 승정원일기는 조선시대의 중요한 역사 기록물로, 방대한 양의 한문 텍스트를 포함하고 있다. 이들 데이터는 한국어와의 평행 코퍼스를 구성할 수 있어, 한문 번역 모델 개발에 있어 귀중한 자원을 제공한다. 그러나 이들 기록물은 고유한 역사적, 문화적 맥락을 가지고 있어, 이를 현대 한국어로 정확히 번역하기 위해서는 단순한 텍스트 변환 이상의 이해가 필요하다.

이들 데이터의 번역 모델을 개발하기 위해서는 텍스트 전처리, 문장 분할 등 다양한 과정이 필요하며, 이를 통해 한문에서 현대 한국어로의 자연스러운 번역이 가능해질 것이다. 특히, Seq2Seq 모델은 이러한 고전 텍스트의 문맥을 잘 이해하고 처리할 수 있는 잠재력을 가지고 있어, 한문 번역에서 유망한 접근 방식으로 평가받고 있다.

2-5. 결론 및 연구의 위치

본 연구는 Seq2Seq 모델을 기반으로 조선왕조실록과 승정원일기 데이터에 적용하여 한문 고전 텍스트를 현대 한국어로 번역하는 모델을 개발하는 것을 목표로 한다. 기존 연구에서 사용된 Seq2Seq 모델의 개념과 방법론을 바탕으로, 한문이라는 특수한 언어의 번역에 맞는 최적의 모델을 제안하고자 한다. 이를 통해 한문학 연구에 기여하고, 한문 번역의 자동화 가능성을 넓히는 데 일조할 것으로 기대된다.

3. 한문 고전 번역 모델 개발

3-1. 데이터 수집

Seq2Seq 모델을 개발하기 위해서는 수십만 개 이상의 한문-번역문 데이터 쌍이 필요하다. 이를 위해, 우리는 국사편찬위원회에서 제공하는 조선왕조실록과 승정원일기의 원문과 번역문 데이터를 크롤링을 통해 수집하였다.

크롤링 코드를 통해 수집된 데이터에 대해 분석을 진행한 결과, 조선왕조실록(1대 태조 ~ 27대 순종)은 임금별 평균 14,016.44개의 문장을 데이터로 가지고 있었고, 승정원일기(인조, 영조, 고종, 순종)는 평균 161,004.25개의 문장을 데이터로 가지고 있었다.

모든 임금을 합친 전체 데이터는 조선왕조실록은 378,444문장, 승정원일기는 644,017문장으로 합쳐서 총 1,022,461개의 문장으로 구성되어 있었다.

3-2. 데이터 전처리


수집한 데이터 중 결측치가 있는 행은 전부 삭제하였고, 그 결과, 1,022,172개의 문장으로 데이터가 감소하였다.

이후, 원문과 번역문에 포함된 불용어들을 모두 제거한 후, 토큰화를 진행하였다. 번역문의 경우, 한국어 토큰화 패키지인 KoNLPy의 OKT(Open Korean Text)를 이용하여 진행하였지만, 원문의 경우, 한문에 대한 토큰화 패키지가 존재하지 않는 관계로 단순히 한자 1개를 단어 1개로 가정하여 토큰화를 진행하였다.

3-3. 모델 설계 및 구현


본 연구에서는 Pytorch 공식문서의 영어-프랑스어 번역 모델을 참고하여 Seq2Seq 기반 번역 모델을 설계하였다. 이 모델은 인코더(Encoder)와 디코더(Decoder)라는 두 개의 RNN으로 구성되며, 어텐션 메커니즘(Attention Mechanism)을 적용하여 번역 품질을 향상시키고자 하였다.

Seq2Seq 모델은 인코더가 입력된 한문 시퀀스를 벡터로 압축하여 출력하고, 디코더는 이 벡터를 기반으로 목표 언어의 시퀀스를 생성하는 구조를 가진다. 본 연구에서 사용된 인코더와 디코더는 GRU(Gated Recurrent Unit) 기반으로 설계되었다.



(그림 1) 한문 번역의 과정


인코더는 입력 시퀀스를 처리하여 각 단어에 대한 벡터와 은닉 상태를 생성하며, 최종 은닉 상태는 전체 시퀀스의 정보를 요약한 벡터로, 디코더의 초기 은닉 상태로 사용된다.



(그림 2) 인코더의 구조

디코더는 인코더에서 생성된 마지막 은닉 상태(맥락 벡터)를 받아, 목표 언어의 시퀀스를 생성한다. 디코딩 과정에서 초기 입력으로 <SOS>(Start Of Sequence)토큰을 사용하고, 각 단계에서 이전 출력과 은닉 상태를 활용하여 다음 단어를 예측

한다.



(그림 3) 디코더의 구조

어텐션 메커니즘은 디코더가 인코더 출력의 특정 부분에 집중할 수 있도록 하여, 문맥 정보가 손실되지 않도록 한다. 이 메커니즘은 디코더의 입력과 은닉 상태를 바탕으로 어텐션 가중치를 계산하고, 이를 통해 인코더 출력의 가중 합을 생성하여 디코더의 예측을 보완한다. 본 연구에서는 Bahdanau Attention를 사용하였다.

3-4. 모델 학습

전체 데이터를 학습시키기에는 시간적인 문제가 있어, 본 연구에서는 5단어 이하의 짧은 문장들(20,091문장)을 뽑아, 학습을 진행해보았다. 또한, 모델을 평가하기 위해, 훈련 데이터와 테스트 데이터를 90 : 10(18,133 : 1,958)으로 나누어주었다.

훈련 데이터는 입력 문장과 목표 문장을 인덱스 형태로 변환하여 텐서로 준비하였다. 각 시퀀스의 끝에는 종료(EOS, End Of Sequence) 토큰을 추가하고, 이를 바탕으로 데이터 로더(data loader)를 통해 배치 단위로 데이터를 처리하였다.


훈련 과정에서는 인코더와 디코더를 사용하여 입력 시퀀스를 처리하고, 목표 시퀀스를 생성하였다. 학습 과정에서 '교사 강요(Teacher Forcing)' 기법을 활용하여 디코더의 입력으로 실제 목표 단어를 사용하고, 이를 통해 모델이 더 빠르게 수렴하도록 하였다. 매 에폭(Epoch)마다 손실 값을 계산하고, 손실 값의 평균을 출력하여 학습 진행 상황을 모니터링하였다.

모델 학습을 위해 설정된 하이퍼파라미터(Hyperparameter) 값은 아래와 같이 구성되었다.

(표1) 하이퍼파라미터 값

은닉 상태 크기 (hidden_size)	128
배치 크기 (batch_size)	32
에포크 수 (n_epochs)	80
학습률 (learning_rate)	0.001

학습은 총 28분 37초가 걸렸고, 에폭마다 손실값을 시각화한 결과는 다음과 같다.



(그림 4) 학습 과정 중 손실값 시각화

에폭마다 손실값이 감소한다는 점에서 학습이 잘 이루어지고 있다는 사실을 알 수 있었다.

3-5. 모델 평가 및 결과 분석

평가의 과정은 훈련 과정과 유사하지만, 정답 레이블이 없기 때문에 디코더의 예측을 다시 사용하는 방식으로 진행된다. 디코더의 예측에서 가장 높은 확률을 가진 단어들이 계속해서 문자열에 추가되며, <EOS>토큰을 예측할 때까지 단어가 계속해서 추가된다.

먼저, 훈련 데이터 중 무작위로 한문 문장을 골라, 모델에 입력해보았다.


(표 2) 훈련 데이터에 대한 번역 결과

원문	庚寅水
번역문	얼음 이 얼었다
예상	가 큰 청나라 <EOS>
원문	壬寅視事
번역문	정사를 보았다
예상	머물렀다 나아갔다 삼전 <EOS>

위의 결과에서 보이다시피, 훈련된 데이터에 대해서도 제대로 번역을 해주지 못하는 것을 알 수 있다. 다음은 테스트 데이터에 대해서 번역을 진행하고, 어텐션 출력을 매트릭스(Matrix) 형태로 시각화한 결과이다.

(표 3) 테스트 데이터에 대한 번역 결과

입력	丙子日有重量
출력	불었다 큰 월식 돌아갔다 <EOS>



(그림5) 테스트 데이터에 대한 어텐션 시각화

우선, 입력된 문장에 대한 번역이 틀린 것과 더불어, 어텐션 시각화 결과 대부분의 값이 0.2 이하로, 모델이 입력문장의 문맥을 거의 이해하지 못했다는 것을 알 수 있다.

모델의 정확도를 높이기 위해, 데이터의 크기를 더 늘려보기도 하고, 하이퍼파라미터 조정을 진행해보기도 하였지만, 유의미하게 정확도가 높아지는 않았기에 본 연구자는 이를 모델 구현 및 학습 과정의 문제보다는 한문과 한국어라는 언어 자체의 특성 때문이라고 판단하였다. 이에 본 연구자는 모델 개발 과정 중 느꼈던 어려움을 토대로, 모델 개발의 실패요인과 더불어 한문학 자연어처리의 어려움을 다음 섹션에서 다뤄 보고자 한다.

4. 한문학 자연어처리의 어려움

4-1. 데이터베이스의 비표준화

한문학 자연어 처리의 주요 문제점 중 하나는 한문 데이터베이스의 저장 방식이 비일관적이라는 것이다. 본 연구자는 학습에 필요한 데이터를 확보하기 위해 한문고전종합DB와 동양고전종합DB의 API를 이용하였으나, 두 데이터베이스는 작품 문헌 간 데이터 저장 방식이 일관되지 않고, 각기 다른 형식과 구조로 데이터를 제공하였다. 이로 인해 데이터 통합과 처리에 어려움을 겪었으며, 비표준화된 데이터 저장 방식이 양질의 한문 데이터 수집을 어렵게 만든다는 것을 확인할 수 있었다.

4-2. 토큰화

한문 텍스트의 토큰화는 전용 패키지가 존재하지 않아 어려움이 있다. 본 연구에서도 한문 토큰화의 어려움으로 인해, 개별 한자를 하나의 단어로 간주하는 방식을 사용하였다. 물론, 중국어를 위한 토큰화 패키지를 이용할 수도 있지만, 고전 한

문과 현대 중국어는 문법 구조와 사용 어휘가 다르기 때문에 신중하게 접근해야 한다.

또한, 한국어 토큰화도 영어나 다른 서양 언어에 비해 어려운 편이다. 이는 한국어의 다양한 어미와 조사를 정확히 분리하는 데 KoNLPy와 같은 도구가 한계를 가지기 때문이다. 게다가, 한국어의 복합 명사 사용도 문제를 일으킬 수 있다. 예를 들어, '사과나무'를 '사과'와 '나무'로 분리하는 것이 항상 적절하지 않을 수 있다.

특히, 한문 고전에서는 현재 사용되지 않는 역사적 어휘가 자주 등장하는데, 이러한 어휘가 사전에 등록되지 않아 KoNLPy가 데이터를 처리하는 데 어려움을 겪을 수 있다. 이로 인해 토큰화 결과가 왜곡될 가능성이 있다.

(표4) 상참(常參)이라는 역사적 단어를 잘못 토큰화한 예시


기존 문장	상참과 경연을 정지하였다
토큰화된 문장	상, 참과, 경연, 을, 정지, 하였다

4-3. 유니코드사용의 문제점

한문 텍스트 처리에서 유니코드를 사용하는 것은 서양 문자를 처리할 때와 비교해 비트 수가 많이 차지된다는 문제점이 있다. 서양 문자들은 주로 ASCII 코드를 사용하여 1바이트(8비트)로 표현되지만, 한문과 같은 비서양 문자는 유니코드를 통해 처리되며, 이는 일반적으로 2바이트(16비트) 또는 그 이상이 필요하다. 이로 인해 전처리 과정에서 더 많은 시간이 소요되며, 메모리 사용량도 증가하게 된다. 특히, 대량의 한문 텍스트를 처리하는 경우 이러한 문제는 더욱 두드러지며, 모델 구현과 학습 과정에서 성능 저하를 일으킬 수 있다. 이는 한문 자연어 처리의 효율성을 낮추는 주요한 요인 중 하나이다.

4-4. 의역된 번역문의 문제

한문 고전을 현대어로 번역할 때, 원문에 비해 지나치게 의역된 번역문이 종종 발생한다. 의역은 의미 전달에 유리할 수 있지만, 자연어 처리 관점에서 원문과 번역문 간의 토큰 길이 차이를 유발하여 불일치를 초래할 수 있다. 이러한 불일치는 기계 번역, 텍스트 분석, 그리고 다른 자연어 처리 작업에서 부정확한 결과를 야기할 수 있다. 예를 들어, 원문은 간결하지만 번역문은 장황하게 표현될 경우, 토큰화 과정에서 불필요한 복잡성이 발생할 수 있으며, 이로 인해 분석 결과가 왜곡될 수 있다.



(그림 6) 한문과 번역문의 토큰 길이 비교

다음은 한문 문장과 한국어 문장의 토큰 길이를 비교한 결과이다. 대부분의 경우, 한문 문장과 한국어 문장의 토큰 길이는 정비례하는 경향을 보였다. 그러나 짧은 문장에서는 한문의 축약적인 표현이 한국어로 번역될 때 지나치게 길어지는 경우가 있었다. 이로 인해 한국어 문장이 한문 문장보다 상대적으로 길어진 사례가 관찰되었다.

4-5. 문자언어로서의 한자의 특성

한자는 의미를 나타내는 문자언어로서, 다른 표음문자와는 다른 특징을 가진다. 한문은 각 글자가 독립적인 의미를 가지므로, 이를 자연어 처리 과정에서 정확하게 분석하는 데 어려움이 있다. 특히, 문맥에 따라 동일한 한자가 여러 가지 의미로 해석될 수 있어 이를 적절히 구분하고 처리하는 것이 중요하다. 이러한 특성은 한문 텍스트의 형태소 분석 및 의미 분석에서 복잡성을 더한다. 또한, 한자는 단순한 음운적 형태가 아닌 의미적 복잡성을 가지기 때문에, 이를 고려하지 않은 단순한 토큰화 방식은 부적절한 결과를 초래할 수 있다.

5. 결론

본 연구는 한문 고전 텍스트의 현대 한국어 번역을 위한 Seq2Seq 기반 번역 모델을 개발하고, 이를 통해 한문학 자연어 처리의 가능성을 탐구하였다. 연구의 주요 목표는 한문 텍스트를 효과적으로 번역하기 위한 모델을 설계하고, 한문학 자연어 처리의 도전 과제를 규명하는 것이었다.

모델 설계 과정에서 Seq2Seq 구조와 어텐션 메커니즘을 채택하여 한문을 현대 한국어로 번역하는 기초적인 틀을 마련하였다. 그러나 연구 결과, 모델의 번역 성능이 기대에 미치지 못하는 것으로 나타났다. 특히, 한문과 현대 한국어 간의 문법적 및 구조적 차이로 인해 번역의 정확도가 부족하였고, 어텐션 메커니즘이 문맥을 효과적으로 반영하지 못하는 문제점이

발견되었다. 이러한 문제는 한문과 현대 언어 간의 깊은 의미적, 문법적 차이에서 기인하는 것으로 판단된다.

[utorial.html?highlight=translation.](#)

한문학 자연어 처리에서의 주요 도전 과제도 규명되었다. 데이터베이스의 비표준화, 토큰화의 어려움, 유니코드 사용으로 인한 메모리 및 처리 시간 문제, 그리고 의역된 번역문으로 인한 토큰 길이 차이 등이 주요 문제로 확인되었다. 이러한 문제들은 한문 고전 텍스트의 번역과 분석을 어렵게 만들며, 향후 연구에서 해결해야 할 중요한 과제로 남아 있다.

향후 연구는 몇 가지 방향으로 나아갈 수 있다. 우선, 데이터 품질을 향상시키기 위해 보다 정교한 데이터 수집 및 전처리 방법을 개발할 필요가 있다. 또한, 한문에 특화된 토큰화 기술의 개발이나 기존 기술의 개선이 요구된다. 모델 성능을 향상시키기 위해 Seq2Seq 모델의 구조를 개선하거나 다른 딥러닝 기법을 도입할 수 있으며, 하이퍼파라미터 조정과 데이터 증강 방법도 효과적인 성능 향상에 기여할 것이다. 더 나아가, 한문 외의 다른 고전 언어와의 번역 연구를 통해 자연어 처리 기술의 적용 범위를 확장할 수 있다.

본 연구는 한문학 연구와 자연어 처리 기술의 융합을 통해 한문 고전 텍스트의 번역 가능성을 탐구하였으며, 향후 한문학 연구의 자동화 및 효율성을 높이는 데 기여할 것으로 기대된다. 본 연구의 결과는 다른 고전 언어 번역 연구에도 중요한 기초 자료로 활용될 수 있으며, 자연어 처리 기술의 발전에 중요한 발판이 될 것이다.

참고문헌

- [1] I. Sutskever, O. Vinyals, Q. V. Le, "Sequence to Sequence Learning with Neural Networks", arXiv preprint, arXiv:1409.3215v3, 2014.
- [2] D. Bahdanau, K. Cho, Y. Bengio, "Neural Machine Translation by Jointly Learning to Align and Translate", arXiv preprint, arXiv:1409.0473v7, 2015.
- [3] 국사편찬위원회, "조선왕조실록", <https://sillok.history.go.kr/>.
- [4] 국사편찬위원회, "승정원일기", <https://sjw.history.go.kr/>.
- [5] K. Kang, K. Jin, S. Yang, S. Jang, J. Choo, Y. Kim, "Restoring and Mining the Records of the Joseon Dynasty via Neural Language Modeling and Machine Translation", arXiv preprint, arXiv:2104.05964v3, 2021.
- [6] S. Robertson, "NLP from scratch: Translation with a sequence to sequence network and attention," PyTorch Tutorials, https://pytorch.org/tutorials/intermediate/seq2seq_translation_t